

**MASTER 1 – Economie Appliquée parcours Conseil économique pour
les organisations publique et privée (CEPOPP)**

Présenté : Jean Etzer CHARLES & Coulibaly MOUSSA

Sous la direction : Mr Jean Baptiste FREDO

Exercice 1. Simulation et estimation d'un AR (3)

1. Proposons des valeurs du vecteur de paramètres $\phi = [\phi_1, \phi_2, \phi_3]^T$ de sorte que le processus AR (3) soit stationnaire

2. Vérifions à l'aide de R que la réponse a la question 1 est correcte.


```
> # Afficher les racines
> print(roots)
[1] -0.1139359+1.697278e+00i -0.1139359-1.697278e+00i  1.7278718-2.775558e-16i
```

Toutes les racines ont un module > 1 (1.7011 et 1.7279). Donc le processus AR (3) est stationnaire.

```
> # Vérifier la stationnarité
> all(Mod(roots) > 1)
[1] TRUE
```

La sortie de `all(Mod(roots) > 1)` est TRUE, alors le processus est stationnaire

3. Simulons un échantillon de taille $T = 1000$ pour le processus avec les valeurs des paramètres qui ont été choisies.



4. Estimons, à l'aide de l'échantillon simulé, le vecteur de paramètres ϕ et l'écart-type ou par le maximum de vraisemblance conditionnelle.

```
> summary(model)
      Length Class  Mode
coef          4 -none-  numeric
sigma2         1 -none-  numeric
var.coef       16 -none-  numeric
mask           4 -none-  logical
loglik         1 -none-  numeric
aic            1 -none-  numeric
arma           7 -none-  numeric
residuals 1000  ts      numeric
call           4 -none-   call
series         1 -none-  character
code           1 -none-  numeric
n.cond         1 -none-  numeric
nobs           1 -none-  numeric
model          10 -none-   list
> |
```

Le modèle AR (3) estimé par maximum de vraisemblance conditionnelle retrouve les paramètres simulés (ex. $\phi_1 \approx 0.5$, $\phi_2 \approx -0.3$, $\phi_3 \approx 0.2$) avec une variance résiduelle proche de 1.

La log-vraisemblance et l'AIC indiquent un bon ajustement, sous réserve de la validation des résidus (absence d'autocorrélation et normalité).


Exercice 2. Identification d'un processus à l'aide la fonction d'autocorrélation

1. Calculer la moyenne de l'échantillon fourni.


```
> moyenne <- mean(donnees)
> print(paste("Moyenne empirique :", round(moyenne, 4)))
[1] "Moyenne empirique : 1.9811"
> |
```

2 : Identifier le processus avec ACF et PACF

ACF des données EXO2



PACF des données EXO2



3: Écriture du processus et estimation des paramètres

```
> summary(modele)
      Length Class      Mode
coef          2   -none-  numeric
sigma2        1   -none-  numeric
var.coef      4   -none-  numeric
mask          2   -none-  logical
loglik        1   -none-  numeric
aic           1   -none-  numeric
arma          7   -none-  numeric
residuals    150    ts      numeric
call          4   -none-   call
series        1   -none-  character
code          1   -none-  numeric
n.cond        1   -none-  numeric
nobs          1   -none-  numeric
model        10   -none-   list
```

Le processus est un AR (1) stationnaire avec une dépendance temporelle positive ($\phi_1 \approx 0.59$), moyenne de long terme ≈ 4.95 , Variance résiduelle modérée ($\sigma^2 = 1.44$).

Donc le modèle est statistiquement valide car tous les coefficients significatifs.

4. Vraisemblance conditionnelle pour un AR (1) :

$$L(\varphi, c, \sigma^2) = \prod_{t=2}^T \frac{1}{\sqrt{2\pi\sigma^2}} \exp\left(-\frac{1}{2\sigma^2}(Y_t - c - \varphi Y_{t-1})^2\right)$$

5: Estimation par Maximum de Vraisemblance

```
> Box.test(residuals(modele), lag = 10, type = "Ljung-Box")

Box-Ljung test

data: residuals(modele)
X-squared = 20.528, df = 10, p-value = 0.02464
```

Test de Ljung-Box (lag 10) a un p -value = 0.0246 (< 0.05) donc Rejet de l'hypothèse de bruit blanc.

ce qui veut dire que les résidus sont autocorrélés, indiquant un ajustement incomplet du modèle.

Pour conclure nous pouvons dire que bien que le modèle AR (1) soit statistiquement significatif, les résidus autocorrélés suggèrent qu'un modèle plus complexe (ex. ARMA) pourrait mieux capturer la dynamique des données.

Exercice 3 : Modèle ARMA(1,2)

On considère le modèle ARMA(1,2) suivant :

$$X_t = 0.8X_{t-1} + u_t + 0.7u_{t-1} + 0.6u_{t-2}, \quad u_t \sim \mathcal{N}(0, \sigma_u^2)$$

(a) Preuve que $\rho(h) = 0.8\rho(h-1)$ pour $h > 2$

On multiplie les deux membres de l'équation par X_{t-h} et on applique la covariance :

$$\text{Cov}(X_t, X_{t-h}) = 0.8 \text{Cov}(X_{t-1}, X_{t-h}) + \text{Cov}(u_t, X_{t-h}) + 0.7 \text{Cov}(u_{t-1}, X_{t-h}) + 0.6 \text{Cov}(u_{t-2}, X_{t-h})$$

Or, pour $h > 2$, les termes u_t, u_{t-1}, u_{t-2} sont indépendants de X_{t-h} , car X_{t-h} dépend uniquement des erreurs passées $u_{t-h}, u_{t-h-1}, \dots$

Donc :

$$\text{Cov}(u_t, X_{t-h}) = \text{Cov}(u_{t-1}, X_{t-h}) = \text{Cov}(u_{t-2}, X_{t-h}) = 0$$

Il en résulte :

$$\gamma(h) = 0.8\gamma(h-1) \quad \Rightarrow \quad \rho(h) = \frac{\gamma(h)}{\gamma(0)} = 0.8\rho(h-1)$$

(b) Preuve que $\rho(2) = 0.8\rho(1) + \frac{0.6\sigma_u^2}{\gamma(0)}$

On calcule $\gamma(2)$:

$$\gamma(2) = \text{Cov}(X_t, X_{t-2}) = 0.8\gamma(1) + \text{Cov}(u_t, X_{t-2}) + 0.7\text{Cov}(u_{t-1}, X_{t-2}) + 0.6\text{Cov}(u_{t-2}, X_{t-2})$$

Par indépendance :

$$\text{Cov}(u_t, X_{t-2}) = \text{Cov}(u_{t-1}, X_{t-2}) = 0$$

$$\text{Cov}(u_{t-2}, X_{t-2}) = \text{Var}(u_{t-2}) = \sigma_u^2$$

Donc :

$$\gamma(2) = 0.8\gamma(1) + 0.6\sigma_u^2 \quad \Rightarrow \quad \rho(2) = \frac{\gamma(2)}{\gamma(0)} = 0.8\rho(1) + \frac{0.6\sigma_u^2}{\gamma(0)}$$

Exercice 4

a) Simulation du processus MA (1) pour $\theta = -0.6$

1. Génération des erreurs u_t :

Les u_t sont des variables aléatoires normales centrées réduites ($u_t \sim N(0, 1)$).

2. Construction de X_t :

Le processus $X_t = u_t + \theta u_{t-1}$ est simulé récursivement :

- $X_1 = u_1 + \theta \cdot u_0 = u_1$ (car $u_0 = 0$),
- Pour $t \geq 2$, $X_t = u_t + \theta u_{t-1}$

b. Log-vraisemblance conditionnelle

La vraisemblance conditionnelle est construite en exprimant les erreurs u_t en fonction des observations X_t et du paramètre θ . Les u_t sont indépendants et suivent $N(0, 1)$.

1. Expression des erreurs :

- $u_1 = X_1 - \theta \cdot u_0 = X_1$,
- $u_t = X_t - \theta \cdot u_{t-1}$ pour $t \geq 2$.

2. Log-vraisemblance :

$$L(\theta) = -2n \log(2\pi) - \frac{1}{2} \sum_{t=1}^n u_t^2,$$

où u_t est calculé récursivement.

c) Estimation de θ par maximum de vraisemblance


```
> print(result$par)
[1] -0.6225468
```

L'estimation $\hat{\theta} \approx -0.6225$ est raisonnable et reflète la vraie valeur du paramètre $\theta = -0.6$ avec une erreur faible, typique des simulations de petite taille. Cela confirme que la procédure d'estimation est correctement implémentée.

Exercice 5. Décomposition d'une série en tendance et cycle

1.Représentation logarithmique de la population américaine.

Évolution logarithmique de la population américaine (1948-2023)



2. Estimation d'une tendance quadratique

On suppose une tendance déterministe quadratique :

$$\log(\text{USPOP}_t) = \beta_0 + \beta_1 t + \beta_2 t^2 + \epsilon_t$$

```
> summary(modele_quad)

Call:
lm(formula = log_population ~ t + I(t^2))

Residuals:
    Min       1Q   Median       3Q      Max
-0.033854 -0.009742  0.001192  0.008021  0.058161

Coefficients:
              Estimate Std. Error t value Pr(>|t|)
(Intercept)  1.147e+01  6.614e-03 1733.67  <2e-16 ***
t             1.828e-02  3.964e-04   46.11  <2e-16 ***
I(t^2)       -6.047e-05  4.989e-06  -12.12  <2e-16 ***
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1


Residual standard error: 0.01872 on 73 degrees of freedom
Multiple R-squared:  0.9963,    Adjusted R-squared:  0.9962
F-statistic: 9762 on 2 and 73 DF,  p-value: < 2.2e-16
```

Interprétation


Le modèle quadratique ajusté sur le logarithme de la population américaine (1948–2023) explique 99,6% de la tendance observée. La croissance annuelle initiale de 1,83% ralentit progressivement, reflétant une possible stabilisation démographique. Bien que le modèle soit performant pour décrire la tendance long terme, les résidus (écarts entre données et modèle) pourraient cacher des cycles ou chocs non pris en compte.

3. Graphiques de la tendance et des écarts

Log(Population) vs. Tendance Quadratique



Écarts par rapport à la Tendance



4. Test d'autocorrélation des écarts (Ljung-Box)

Box-Ljung test

```
data: ecarts
```

```
X-squared = 63.599, df = 1, p-value = 1.554e-15
```

On remarque, $p\text{-value} \approx 1.55e-15$ (beaucoup plus petite que 0.05).

Rejet de H_0 : Les écarts sont significativement autocorrélés au lag 1.

À la vue de ce résultat la tendance quadratique ne capture pas toute la dynamique temporelle de la série. Les écarts résiduels contiennent une dépendance temporelle (ex. cycles, chocs persistants), ce qui invalide l'hypothèse de bruit blanc pour les résidus.

5. Test de racine unitaire

```
> summary(adf_test)
```

```
#####  
# Augmented Dickey-Fuller Test Unit Root Test #  
#####  
  
Test regression trend  
  
Call:  
lm(formula = z.diff ~ z.lag.1 + 1 + tt + z.diff.lag)  
  
Residuals:  
      Min       1Q   Median       3Q      Max   
-0.0156986 -0.0019434 -0.0001878  0.0018468  0.0109778  
  
Coefficients:  
              Estimate Std. Error t value Pr(>|t|)      
(Intercept)  5.663e-02  1.695e-01   0.334    0.739      
z.lag.1      -4.351e-03  1.475e-02  -0.295    0.769      
tt           2.474e-05  2.054e-04   0.120    0.904      
z.diff.lag    5.979e-01  9.944e-02   6.013 7.44e-08 ***  
---  
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1  
  
Residual standard error: 0.003768 on 70 degrees of freedom  
Multiple R-squared:  0.4324,    Adjusted R-squared:  0.4081  
F-statistic: 17.78 on 3 and 70 DF,  p-value: 1.11e-08  
  
Value of test-statistic is: -0.295 5.7182 1.3941  
  
Critical values for test statistics:  
      1pct  5pct 10pct  
tau3 -4.04 -3.45 -3.15  
phi2  6.50  4.88  4.16  
phi3  8.73  6.49  5.47
```

La statistique de test (-0.295) est supérieure à toutes les valeurs critiques.
On ne peut pas rejeter l'hypothèse nulle car nous avons la présence d'une racine unitaire

La série logarithmique de la population américaine n'est pas donc stationnaire.

Les codes R

exercice 1

#question 2

#Verifions que la reponse a la question 1 est correcte.

Définition des coefficients

```
phi <- c(0.5, -0.3, 0.2)
```

Trouver les racines du polynôme caractéristique

```
roots <- polyroot(c(1, -phi))
```

Afficher les racines

```
print(roots)
```

Vérifier la stationnarité

```
all(Mod(roots) > 1)
```

#question 3

```
set.seed(123) # Pour la reproductibilité
```

Paramètres

```
T <- 1000
```

```
phi1 <- 0.5
```

```
phi2 <- -0.3
```

```
phi3 <- 0.2
```

```
sigma_u <- 1
```

Simulation du bruit blanc

```
u <- rnorm(T, mean = 0, sd = sigma_u)
```

Initialisation de Y avec les conditions $Y(-2) = Y(-1) = Y(0) = 0$

```
Y <- numeric(T)
```

```
Y[1:3] <- 0
```

Génération de la série AR(3)

```
for (t in 4:T) {
```

```
  Y[t] <- phi1 * Y[t-1] + phi2 * Y[t-2] + phi3 * Y[t-3] + u[t]
```

```
}
```

Visualisation de la série

```
plot(Y, type = "l", main = "Simulation d'un processus AR(3)")
```

```
#question 4
```

```
# Estimation du modèle AR(3)
```

```
model <- arima(Y, order = c(3,0,0), method = "ML")
```

```
# Afficher les résultats
```

```
summary(model)
```

#exercice 2

```
library(tseries)
```

```
# Lire toutes les lignes du fichier
```

```
lignes <- readLines("C:/Users/couli/Downloads/EXO2.txt")
```

```
# Supprimer la première ligne
```

```
donnees_brutes <- lignes[-1]
```

```
# Enlever les guillemets et les espaces superflus
```

```
donnees_nettoyees <- gsub("'", "", donnees_brutes)
```

```
donnees_nettoyees <- trimws(donnees_nettoyees)
```

```
# Convertir en numérique
```

```
donnees <- as.numeric(donnees_nettoyees)
```

```
head(donnees)
```

question 1

```
moyenne <- mean(donnees)
```

```
print(paste("Moyenne empirique :", round(moyenne, 4)))
```

question 2

```
acf(donnees, main = "ACF des données EXO2")
pacf(donnees, main = "PACF des données EXO2")
```

question 3

```
modele <- arima(donnees, order = c(1, 0, 0), include.mean = TRUE)
summary(modele)
```

question 5

```
Box.test(residuals(modele), lag = 10, type = "Ljung-Box")
```

#exercice 4

question a

```
set.seed(123)
n <- 100
theta <- -0.6
u <- rnorm(n, mean = 0, sd = 1)
X <- numeric(n)
X[1] <- u[1] # u0 = 0
for (t in 2:n) {
  X[t] <- u[t] + theta * u[t-1]}

```

question c

```
loglik <- function(theta, data) {
  n <- length(data)
  u <- numeric(n)
  u[1] <- data[1] # u0 = 0
  for (t in 2:n) {

```

```

u[t] <- data[t] - theta * u[t-1] }
-sum(dnorm(u, mean = 0, sd = 1, log = TRUE))}
result <- optim(par = 0.5, fn = loglik, data = X, method = "BFGS")
theta_hat <- result$par
print(result$par)

```

#exercice 5

question 1

```
library(readxl)
```

```
library(urca)
```

Importer les données

```
data <- read_excel("C:/Users/couli/Downloads/EXO3 (1).xls")
```

```
years <- data$Année
```

```
population <- data$USPOP
```

Calculer le logarithme de la population

```
log_population <- log(population)
```

Tracer la série en échelle logarithmique

```
plot(years, log_population, type = "l",
```

```
      xlab = "Année", ylab = "Log(Population)",
```

```
      main = "Évolution logarithmique de la population américaine (1948-2023)")
```

question 2

Créer une variable de temps (t = 1, 2, ..., 76)

```
t <- 1:length(years)
```

Estimation du modèle quadratique

```
modele_quad <- lm(log_population ~ t + I(t^2))
```

```
summary(modele_quad)
```

question 3

```
# Valeurs ajustées de la tendance
```

```
tendance <- fitted(modele_quad)
```

```
# Écarts entre log-population et tendance
```

```
ecarts <- log_population - tendance
```

```
# Graphique 2 : Log-population et tendance
```

```
plot(years, log_population, type = "l", col = "blue",  
      xlab = "Année", ylab = "Log(Population)",  
      main = "Log(Population) vs. Tendance Quadratique")  
lines(years, tendance, col = "red", lwd = 2)  
legend("topleft", legend = c("Données", "Tendance"),  
      col = c("blue", "red"), lty = 1)
```

```
# Graphique 3 : Écarts
```

```
plot(years, ecarts, type = "l", col = "green",  
      xlab = "Année", ylab = "Écarts",  
      main = "Écarts par rapport à la Tendance")
```

question 4

```
# Test de Ljung-Box pour un ordre 1
```

```
Box.test(ecarts, lag = 1, type = "Ljung-Box")
```

question 5

```
# Test ADF avec 1 retard
```

```
adf_test <- ur.df(log_population, type = "trend", lags = 1)  
summary(adf_test)
```