

# DEVOIR DE MICRO-ÉCONOMÉTRIE

ANNEE UNIVERSITAIRE 2024-2025

***PRÉSENTÉ PAR :***

**COULIBALY MOUSSA  
Jean Etzer CHARLES**

**FORMATON : MASTER 1 – ECONOMIE APPLIQUEE PARCOURS CEPOPP  
CHARGE DU COURS : Yves Arrighi – Université de Lille**

## I. Présentation des données

La base de donnée proposée à notre étude se nomme “mastercard\_appr.csv”.

Cette base de donnée contient 1019 observations et 16 variables, dont 12 variables quantitatives et 4 variables

Qualitatives.

Les variables étudiées sont les suivantes :

- ID : représente l'identifiant client.
- SEXE : représente le sexe du client.
- AGE : représente l'âge du client.
- SITUA\_F : représente sa situation familiale.
- ANCIENNETE : représente l'ancienneté du client dans la banque (en mois).
- CSP : représente la catégorie socio-professionnelle du client.
- MOUV\_CRED : représente le mouvement créditeur moyen du client sur les 3 derniers mois (en k€).
- AVOIRS : représente les avoirs du client au sein de la banque (en €).
- TX\_ENDET : représente le taux d'endettement du client (en %).
- CREDITS : représente le montant des crédits en cours du client (en €).
- NB\_COMPTE : représente le nombre de comptes ouverts du client.
- SOLDE\_CC : représente le solde moyen du compte courant sur les 3 derniers mois (en€).
- DER\_MOUV : représente l'âge du dernier mouvement du client (en jours).
- NB\_OP : représente le nombre d'opérations du client.
- NBJ\_DECOUVERT : représente le nombre de jours à découvert du client au cours des 3 derniers mois.
- GOLD : indique si le client est souscripteur d'une carte Gold.

: représente le nombre d'opérations du client.

- NBJ\_DECOUVERT : représente le nombre de jours à découvert du client au cours des 3 derniers mois.
- GOLD : indique si le client est souscripteur d'une carte Gold.

## II. Traitements des données

En ce qui concerne le traitement des données, nous avons effectués différente transformation depuis la base de donnée original.

Nous avons transformé les 4 variables qualitatives (SEXE, SITUA\_F, CSP et GOLD) en variables dichotomiques.

- La variable SEXE devient une variable dichotomique intitulée SEXE\_BIN.
- La variable SITUA\_F (situation familiale) est transformé en plusieurs variables dichotomiques
  - CELIB pour célibataire.
  - DIVORCE pour divorcé.
  - MARIE pour marier.
  - SEPARE pour séparé.
  - ULIBRE pour en Union Libre.
  - VEUF pour veuf.

- La variable CSP (catégorie socio-professionnelle) est également transformé en plusieurs variables dichotomiques.
  - AGRI pour agriculteur.
  - ARTI pour artisan.
  - CADRE pour cadre.
  - EMP pour les employés.
  - INA pour les clients inactifs.
  - OUV pour les ouvriers.
  - PINT pour les professions intermédiaires.
  - RETR pour les clients retraités.
  - SANSEMP pour les clients sans-emplois.
- Et dernièrement, nous transformons la variable GOLD (clients souscripteur d'une carte Gold) en une variable dichotomique intitulé GOLD\_NUM.

### Table des valeurs manquantes (NA) contenues dans les variables

```
# Vérification des valeurs manquantes
colSums(is.na(df2))
```

|           |         |               |          |            |          |
|-----------|---------|---------------|----------|------------|----------|
| ID        | SEXE    | AGE           | SITUA_F  | ANCIENNETE | CSP      |
| 0         | 0       | 0             | 0        | 0          | 0        |
| MOUV_CRED | AVOIRS  | TX_ENDET      | CREDITS  | NB_COMPTES | SOLDE_CC |
| 0         | 0       | 0             | 0        | 0          | 0        |
| DER_MOUV  | NB_OP   | NBJ_DECOUVERT | SEXE_BIN | GOLD_NUM   | CELIB    |
| 0         | 0       | 0             | 0        | 0          | 0        |
| DIVORCE   | MARIE   | SEPARE        | ULIBRE   | VEUF       | AGRI     |
| 0         | 0       | 0             | 0        | 0          | 0        |
| ARTI      | CADRE   | EMP           | INA      | OUV        | PINT     |
| 0         | 0       | 0             | 0        | 0          | 0        |
| RETR      | SANSEMP |               |          |            |          |
| 0         | 0       |               |          |            |          |

Nous constatons à partir du tableau 1 que les variables de notre étude ne contiennent aucune valeur manquante.

Cependant, en analysant les données, nous relevons certaines incohérences. Par exemple, l'ancienneté de certains clients dans la banque dépasse leur âge, ce qui est illogique. Pour garantir la cohérence des données, nous décidons de conserver uniquement les observations où l'ancienneté du client (exprimée en années, soit ANCIENNETE/12) est inférieure ou égale à son âge.

De plus, nous supprimons l'observation correspondant à l'identifiant client 331, qui présente des valeurs aberrantes : ce client est âgé de 64 ans alors que son ancienneté dans la banque est de 63,75 ans (soit 765 mois), ce qui semble improbable.


Enfin, un autre point clé du nettoyage des données concerne le taux d'endettement (TX\_ENDET). Étant donné que le taux d'endettement maximal autorisé par la Banque de France est de 35 % (assurance comprise) selon la rédaction de Meilleurtaux (s.d.), nous éliminons les observations dont le taux d'endettement dépasse ce seuil.

## II. Statistiques Descriptives

Concernant l'analyse des statistiques descriptives, les relations suivantes peuvent être mises en évidence.



## Statistique Descriptives de la variable AGE

|   | min_age | q1_age | median_age | mean_age | q3_age | max_age | sd_age   |
|---|---------|--------|------------|----------|--------|---------|----------|
| 1 | 18      | 32     | 42         | 42.08008 | 51     | 65      | 11.76403 |



L'âge des clients varie de 18 à 65 ans, avec une moyenne de 42 ans et un écart-type de 11,76 ans. La répartition est équilibrée, avec une médiane de 42 ans et des quartiles indiquant que 50 % des clients ont entre 32 et 51 ans.

## STATISTIQUES DESCRIPTIVES DE DISTRBUTION DE L'ANCIENNETÉ ET DU MOUVEMENT CRÉDITEUR



```
> summary(df2$ANCIENNETE)
  Min. 1st Qu.  Median    Mean 3rd Qu.    Max.
   1.0   41.0   130.0   132.8   206.0   393.0
> summary(df2$MOUV_CRED)
  Min. 1st Qu.  Median    Mean 3rd Qu.    Max.
 0.000   1.000   3.667   9.928   9.000 573.667
```

## Interprétation :

### 1. Ancienneté (ANCIENNETE, en mois)

L'ancienneté des clients varie de **1 à 393 mois** (~32,8 ans), avec une médiane de **130 mois** (~10,8 ans) et une moyenne de **132,8 mois** (~11 ans). La distribution est étalée, avec 75 % des clients ayant moins de **206 mois** (~17,2 ans) d'ancienneté.

### 2. Mouvement créditeur (MOUV\_CRED, en k€ sur 3 mois)

Les mouvements créditeurs vont de **0 à 573,667 k€**, avec une médiane de **3,667 k€** (~3 667 €) et une moyenne plus élevée (**9,928 k€**) en raison de valeurs extrêmes. La majorité des clients ont un mouvement créditeur inférieur à **9 k€**, mais certains ont des montants très élevés, créant une forte dispersion.

## Description des Variables numériques

```
> # Statistiques générales des variables numériques
> summary(df2[, c("AGE", "ANCIENNETE", "MOUV_CRED", "AVOIRS", "TX_ENDET",
+               "CREDITS", "NB_COMPTES", "SOLDE_CC", "DER_MOUV", "NB_OP", "NBJ_DECOUVEF
T")])
```

| AGE           | ANCIENNETE    | MOUV_CRED      | AVOIRS         | TX_ENDET       |
|---------------|---------------|----------------|----------------|----------------|
| Min. :18.00   | Min. : 1.0    | Min. : 0.000   | Min. : 0       | Min. : 0.000   |
| 1st Qu.:32.00 | 1st Qu.: 41.0 | 1st Qu.: 1.000 | 1st Qu.: 0     | 1st Qu.: 0.000 |
| Median :42.00 | Median :130.0 | Median : 3.667 | Median : 1872  | Median : 0.000 |
| Mean :42.08   | Mean :132.8   | Mean : 9.928   | Mean : 17754   | Mean : 3.509   |
| 3rd Qu.:51.00 | 3rd Qu.:206.0 | 3rd Qu.: 9.000 | 3rd Qu.: 18411 | 3rd Qu.: 4.000 |
| Max. :65.00   | Max. :393.0   | Max. :573.667  | Max. :323333   | Max. :35.000   |

| CREDITS       | NB_COMPTES    | SOLDE_CC        | DER_MOUV      | NB_OP          |
|---------------|---------------|-----------------|---------------|----------------|
| Min. : 0      | Min. :0.000   | Min. : -23350.0 | Min. : 0.0    | Min. : 0.00    |
| 1st Qu.: 0    | 1st Qu.:1.000 | 1st Qu.: 137.7  | 1st Qu.: 13.0 | 1st Qu.: 6.00  |
| Median : 0    | Median :1.000 | Median : 1419.7 | Median : 13.0 | Median : 25.00 |
| Mean : 23829  | Mean :1.019   | Mean : 3390.3   | Mean : 19.3   | Mean : 29.17   |
| 3rd Qu.: 8965 | 3rd Qu.:1.000 | 3rd Qu.: 3538.3 | 3rd Qu.: 14.0 | 3rd Qu.: 43.00 |
| Max. :1157646 | Max. :4.000   | Max. : 80609.0  | Max. :944.0   | Max. :262.00   |

| NBJ_DECOUVERT |
|---------------|
| Min. : 0.00   |
| 1st Qu.: 0.00 |
| Median : 0.00 |
| Mean : 11.96  |
| 3rd Qu.: 9.00 |
| Max. :134.00  |

**Interprétation :** Les clients ont entre 18 et 65 ans, avec une ancienneté allant jusqu'à 32,8 ans. Les finances sont très hétérogènes : certains clients ont des avoirs et mouvements créditeurs très élevés, tandis que la médiane reste modeste (1 872 € d'avoir, 3 667 € de mouvements créditeurs). La majorité n'a pas de crédits en cours ni de découvert fréquent, et leur taux d'endettement est souvent faible (médiane = 0 %). Le nombre d'opérations et le solde du compte courant varient fortement, reflétant des profils financiers diversifiés.

## Description des Variables binaires

```
> # Statistiques des variables binaires (sexe, situation familiale, CSP, GOLD_NUM)
> summary(df2[, c("SEXE_BIN", "GOLD_NUM", "CELIB", "DIVORCE", "MARIE", "SEPRE",
+               "ULIBRE", "VEUF", "AGRI", "ARTI", "CADRE", "EMP", "INA", "OUV",
+               "PINT", "RETR", "SANSEMP")])
```

| SEXE_BIN       | GOLD_NUM       | CELIB          | DIVORCE         | MARIE          |
|----------------|----------------|----------------|-----------------|----------------|
| Min. :0.0000   | Min. :0.0000   | Min. :0.0000   | Min. :0.00000   | Min. :0.0000   |
| 1st Qu.:0.0000 | 1st Qu.:0.0000 | 1st Qu.:0.0000 | 1st Qu.:0.00000 | 1st Qu.:0.0000 |
| Median :1.0000 | Median :0.0000 | Median :0.0000 | Median :0.00000 | Median :1.0000 |
| Mean :0.6133   | Mean :0.3256   | Mean :0.3562   | Mean :0.08325   | Mean :0.5005   |
| 3rd Qu.:1.0000 | 3rd Qu.:1.0000 | 3rd Qu.:1.0000 | 3rd Qu.:0.00000 | 3rd Qu.:1.0000 |
| Max. :1.0000   | Max. :1.0000   | Max. :1.0000   | Max. :1.00000   | Max. :1.0000   |

| SEPRE          | ULIBRE          | VEUF             | AGRI             |
|----------------|-----------------|------------------|------------------|
| Min. :0.0000   | Min. :0.00000   | Min. :0.000000   | Min. :0.000000   |
| 1st Qu.:0.0000 | 1st Qu.:0.00000 | 1st Qu.:0.000000 | 1st Qu.:0.000000 |
| Median :0.0000 | Median :0.00000 | Median :0.000000 | Median :0.000000 |
| Mean :0.0137   | Mean :0.03688   | Mean :0.009484   | Mean :0.001054   |
| 3rd Qu.:0.0000 | 3rd Qu.:0.00000 | 3rd Qu.:0.000000 | 3rd Qu.:0.000000 |
| Max. :1.0000   | Max. :1.00000   | Max. :1.000000   | Max. :1.000000   |

| ARTI            | CADRE          | EMP            | INA       | OUV             |
|-----------------|----------------|----------------|-----------|-----------------|
| Min. :0.00000   | Min. :0.0000   | Min. :0.0000   | Min. :0   | Min. :0.00000   |
| 1st Qu.:0.00000 | 1st Qu.:0.0000 | 1st Qu.:0.0000 | 1st Qu.:0 | 1st Qu.:0.00000 |
| Median :0.00000 | Median :0.0000 | Median :0.0000 | Median :0 | Median :0.00000 |
| Mean :0.02529   | Mean :0.2571   | Mean :0.2771   | Mean :0   | Mean :0.07903   |
| 3rd Qu.:0.00000 | 3rd Qu.:1.0000 | 3rd Qu.:1.0000 | 3rd Qu.:0 | 3rd Qu.:0.00000 |
| Max. :1.00000   | Max. :1.0000   | Max. :1.0000   | Max. :0   | Max. :1.00000   |


| PINT           | RETR            | SANSEMP        |
|----------------|-----------------|----------------|
| Min. :0.0000   | Min. :0.00000   | Min. :0.0000   |
| 1st Qu.:0.0000 | 1st Qu.:0.00000 | 1st Qu.:0.0000 |
| Median :0.0000 | Median :0.00000 | Median :0.0000 |
| Mean :0.1538   | Mean :0.01581   | Mean :0.1907   |
| 3rd Qu.:0.0000 | 3rd Qu.:0.00000 | 3rd Qu.:0.0000 |
| Max. :1.0000   | Max. :1.00000   | Max. :1.0000   |

## Interprétation

L'analyse des variables qualitatives montre que 32,56 % des clients ont souscrit à la carte Gold, avec une majorité d'hommes (61,33 %). La situation familiale révèle que 50,05 % sont mariés, 35,62 % célibataires, et une faible proportion est divorcée (8,33 %), séparée (1,37 %) ou veuve (0,95 %). Concernant la catégorie socio-professionnelle, les employés (27,71 %) et les cadres (25,71 %) sont les plus représentés, tandis que 19,07 % sont sans emploi. Pour affiner l'analyse, il faudra comparer les taux de souscription selon ces caractéristiques, réaliser des tests du  $\chi^2$  pour identifier les variables les plus discriminantes, puis construire un modèle logistique binaire afin de prédire la probabilité d'adhésion à la carte Gold et élaborer un score d'appétence.



## Répartition des catégories situations familiales



Aucune entrée de  
été trouvée.


```
table des matières n'a  
> print(prop_data)
```

| Situation_Familiale | Count | Proportion  |
|---------------------|-------|-------------|
| CELIB               | 338   | 0.356164384 |
| DIVORCE             | 79    | 0.083245522 |
| MARIE               | 475   | 0.500526870 |
| SEPRE               | 13    | 0.013698630 |
| ULIBRE              | 35    | 0.036880927 |
| VEUF                | 9     | 0.009483667 |

### Interprétation :

La variable *Situation Familiale* présente une répartition inégale au sein de l'échantillon. Les individus mariés représentent la moitié de l'échantillon (50 %), suivis par les célibataires (35,6 %), ce qui en fait les deux groupes dominants. Les autres modalités sont beaucoup moins fréquentes : divorcés (8,3 %), union libre (3,7 %), séparés (1,4 %) et veufs (0,9 %). Cette faible représentativité de certaines catégories peut poser problème lors de l'estimation du modèle logistique. Il peut donc être pertinent, pour des raisons statistiques et interprétatives, de regrouper les modalités minoritaires – *séparé*, *union libre* et *veuf* – en une seule catégorie intitulée "Autres". Ce regroupement permettrait de renforcer la robustesse du modèle tout en conservant une lecture claire des effets des différentes situations familiales.

## Répartition des catégories situations SCP



|         | Catégorie | Count | Proportion  |
|---------|-----------|-------|-------------|
| AGRI    | AGRI      | 1     | 0.001053741 |
| ARTI    | ARTI      | 24    | 0.025289779 |
| CADRE   | CADRE     | 244   | 0.257112750 |
| EMP     | EMP       | 263   | 0.277133825 |
| INA     | INA       | 0     | 0.000000000 |
| OUV     | OUV       | 75    | 0.079030558 |
| PINT    | PINT      | 146   | 0.153846154 |
| RETR    | RETR      | 15    | 0.015806112 |
| SANSEMP | SANSEMP   | 181   | 0.190727081 |

### Interprétation :

L'analyse de la répartition des catégories socio-professionnelles montre que la majorité des clients sont employés (27,71 %) ou cadres (25,71 %), ce qui représente plus de la moitié de l'échantillon. Les professions intermédiaires (PINT, 15,38 %) et les sans emploi (SANSEMP, 19,07 %) constituent également une part significative. Les ouvriers (OUV, 7,90 %) sont moins nombreux, tout comme les artisans (ARTI, 2,53 %) et les retraités (RETR, 1,58 %). Enfin, les agriculteurs (AGRI, 0,10 %) sont quasi inexistants, et aucune personne n'appartient à la catégorie INA. Ces proportions devront être mises en relation avec la souscription à la carte Gold pour identifier les catégories les plus susceptibles d'y adhérer.



### Scoring : table des coefficients de la régression logistique.

```
> # Entraînement du modèle GLM
> model <- glm(GOLD_NUM ~ ., data = data.frame(GOLD_NUM = y_train, X_train_scaled),
+             family = binomial)
> # Affichage du résumé du modèle
> summary(model)
```

```
Call:
glm(formula = GOLD_NUM ~ ., family = binomial, data = data.frame(GOLD_NUM = y_train,
```

Coefficients: (3 not defined because of singularities)

|               | Estimate | Std. Error | z value | Pr(> z ) |     |
|---------------|----------|------------|---------|----------|-----|
| (Intercept)   | -0.71139 | 17.17408   | -0.041  | 0.966959 |     |
| AGE           | 0.13345  | 0.13431    | 0.994   | 0.320413 |     |
| ANCIENNETE    | -0.37619 | 0.10723    | -3.508  | 0.000451 | *** |
| MOUV_CRED     | 1.16345  | 0.39121    | 2.974   | 0.002939 | **  |
| AVOIRS        | 0.24337  | 0.10849    | 2.243   | 0.024873 | *   |
| TX_ENDET      | -0.15301 | 0.11025    | -1.388  | 0.165180 |     |
| CREDITS       | 0.49357  | 0.19487    | 2.533   | 0.011314 | *   |
| NB_COMPTES    | 0.51680  | 0.11998    | 4.307   | 1.65e-05 | *** |
| SOLDE_CC      | 0.16273  | 0.09862    | 1.650   | 0.098925 | .   |
| DER_MOUV      | -1.42715 | 0.69573    | -2.051  | 0.040239 | *   |
| NB_OP         | 0.06390  | 0.12274    | 0.521   | 0.602625 |     |
| NBJ_DECOUVERT | 0.17724  | 0.10201    | 1.738   | 0.082296 | .   |
| SEXE_BIN      | 0.74139  | 0.10800    | 6.865   | 6.67e-12 | *** |
| CELIB         | -0.60912 | 0.41750    | -1.459  | 0.144569 |     |
| DIVORCE       | -0.21253 | 0.24738    | -0.859  | 0.390266 |     |
| MARIE         | -0.63777 | 0.42820    | -1.489  | 0.136375 |     |
| SEPRE         | -0.11480 | 0.13813    | -0.831  | 0.405908 |     |
| ULIBRE        | -0.24002 | 0.18169    | -1.321  | 0.186494 |     |
| VEUF          | NA       | NA         | NA      | NA       |     |
| AGRI          | -0.50724 | 128.42305  | -0.004  | 0.996849 |     |
| ARTI          | 2.93981  | 103.48238  | 0.028   | 0.977336 |     |
| CADRE         | 0.52987  | 0.14727    | 3.598   | 0.000321 | *** |
| EMP           | 0.09245  | 0.14870    | 0.622   | 0.534140 |     |
| INA           | NA       | NA         | NA      | NA       |     |
| OUV           | -0.33420 | 0.14515    | -2.302  | 0.021310 | *   |
| PINT          | 0.38924  | 0.12771    | 3.048   | 0.002304 | **  |
| RETR          | 0.08276  | 0.08745    | 0.946   | 0.343946 |     |
| SANSEMP       | NA       | NA         | NA      | NA       |     |

---  
Signif. codes: 0 '\*\*\*' 0.001 '\*\*' 0.01 '\*' 0.05 '.' 0.1 ' ' 1

(Dispersion parameter for binomial family taken to be 1)

Null deviance: 1197.68 on 948 degrees of freedom  
Residual deviance: 769.61 on 924 degrees of freedom  
AIC: 819.61

Number of Fisher Scoring iterations: 16

Interprétation :

Ce modèle de régression logistique permet d'identifier les facteurs influençant la probabilité de souscription à la carte Gold. Il met en évidence plusieurs variables explicatives significatives, ayant un impact positif ou négatif sur cette probabilité.

## 1. Facteurs augmentant la probabilité de souscription

Mouvements créditeurs (MOUV\_CRED: +1.16,  $p=0.0029$ )

→ Plus un client a des mouvements créditeurs élevés sur son compte, plus il est susceptible de souscrire à la carte Gold. Cela peut s'expliquer par le fait que la banque considère ces clients comme plus solvables et donc plus éligibles à l'offre.

Avoirs bancaires (AVOIRS : +0.24,  $p = 0.0249$ )

Un niveau d'avoirs plus important favorise la souscription. Cela peut refléter une corrélation entre la capacité d'épargne et l'intérêt pour des services bancaires premium comme la carte Gold.

Montant des crédits en cours (CREDITS: +0.49,  $p = 0.0113$ )

→ Un client ayant des crédits en cours est plus susceptible de souscrire à la carte. Cela peut indiquer que les clients ayant une plus grande activité financière et un besoin de financement sont plus attirés par des produits bancaires complémentaires.

Nombre de comptes détenus (NB\_COMPTES : +0.52,  $p < 0.0001$ )

→ Plus un client possède de comptes, plus il est enclin à souscrire à une carte Gold. Cela peut être lié à une gestion bancaire plus complexe et un besoin accru de services exclusifs.

Sexe (SEXE\_BIN : +0.74,  $p < 0.0001$ )

→ Les hommes sont significativement plus enclins à souscrire à une carte Gold que les femmes. Cela pourrait être lié à des différences de comportement financier, de revenus ou d'intérêt pour les produits bancaires premium.

Statut professionnel

→ Cadres (CADRE : +0.53,  $p = 0.0003$ ) et professions intermédiaires (PINT : +0.39,  $p = 0.0023$ ) sont plus susceptibles de souscrire. Leur revenu plus élevé et leur besoin de services financiers spécifiques pourraient expliquer cette tendance.

## 2. Facteurs réduisant la probabilité de souscription

Ancienneté dans la banque (ANCIENNETE : -0.38,  $p = 0.0004$ )

→ Plus un client est ancien, moins il a tendance à souscrire à la carte Gold. Cela peut être dû au fait que les clients fidèles disposent déjà d'une carte bancaire qui leur convient ou qu'ils n'éprouvent pas le besoin de changer d'offre.

Dernier mouvement bancaire (DER\_MOUV : -1.43,  $p = 0.0402$ )

→ Un dernier mouvement bancaire ancien réduit la probabilité de souscription. Cela

suggère que les clients inactifs sont moins enclins à souscrire à une carte Gold, probablement car ils ont moins d'interactions avec la banque.

Statut professionnel : Ouvriers (OUV :  $-0.33$ ,  $p = 0.0213$ )

→ Les ouvriers sont moins susceptibles de souscrire, ce qui peut s'expliquer par des niveaux de revenus plus bas ou une moindre appétence pour les services bancaires premium.

### **3. Variables non significatives ( $p > 0.1$ )**

Âge (AGE :  $p = 0.32$ )

→ L'âge ne semble pas avoir d'impact significatif sur la souscription. Cela pourrait indiquer que les comportements financiers en matière de carte bancaire ne sont pas strictement liés à l'âge, mais plutôt à la situation économique et professionnelle.

Situation familiale

→ Célibataire (CELIB :  $p = 0.14$ ), marié (MARIE :  $p = 0.13$ ), divorcé (DIVORCE :  $p = 0.39$ ), séparé (SEPRE :  $p = 0.40$ ) et en union libre (ULIBRE :  $p = 0.18$ ) ne montrent pas d'effet significatif sur la souscription. Cela peut indiquer que la situation familiale n'est pas un facteur déterminant dans la décision d'adhérer à une carte Gold.

Taux d'endettement (TX\_ENDET :  $p = 0.16$ )

→ Bien que le taux d'endettement puisse jouer un rôle dans l'éligibilité au crédit, il n'a pas d'effet clair sur la souscription à la carte Gold.

Solde du compte courant (SOLDE\_CC :  $p = 0.098$ )

→ Une corrélation marginale est observée : un solde plus élevé pourrait favoriser la souscription, mais son effet reste incertain.

Nombre d'opérations bancaires (NB\_OP :  $p = 0.60$ )

→ L'activité bancaire ne semble pas être un indicateur déterminant pour la souscription à la carte Gold.

### **4. Variables exclues pour singularité**

Certaines variables n'ont pas pu être incluses dans le modèle en raison de colinéarité ou d'un manque de variance :

VEUF, INA, SANSEMP n'apportent pas d'information supplémentaire et sont exclus du modèle.


### **5. Performance du modèle**

AIC = 819.61 : Une valeur relativement basse, indiquant un bon compromis entre complexité et performance du modèle.

Nulle déviance = 1197.68 → Residual deviance = 769.61 : La réduction de la déviance montre que le modèle ajuste bien les données et qu'il a un pouvoir prédictif significatif.

Donc, ce modèle met en évidence plusieurs facteurs influençant la souscription à la carte Gold. Les éléments financiers (mouvements créditeurs, avoirs, crédits, nombre de comptes) sont les plus déterminants, car ils traduisent le dynamisme bancaire du client et son niveau de ressources. Le sexe joue un rôle important, les hommes étant plus enclins à souscrire que les femmes. Le statut professionnel influence aussi la décision : les cadres et professions intermédiaires sont plus susceptibles d'adhérer, tandis que les ouvriers le sont moins. À l'inverse, une grande ancienneté bancaire ou un manque d'activité récente sont des freins à la souscription.

Pour améliorer la performance du modèle, il serait intéressant d'explorer des interactions entre variables ou d'utiliser des techniques de sélection de variables pour affiner l'analyse.



#### **AUC du modèle : 0.8874343**

Avec une AUC de 0.8874, le modèle logistique présente une très bonne capacité discriminante pour prédire la souscription à la carte Gold, indiquant qu'il sépare efficacement les souscripteurs des non-souscripteurs. Cette valeur signifie que le modèle classe correctement un individu souscripteur et un non-souscripteur dans près de 89 % des cas, minimisant ainsi les erreurs de classification. Un tel score garantit une précision élevée dans l'attribution d'un score d'appétence, ce qui est essentiel pour le ciblage marketing. Toutefois, des améliorations restent possibles, comme l'optimisation du seuil de classification ou l'exploration de modèles alternatifs (arbres de décision, random forests) pour affiner encore les prédictions. En l'état, ce modèle constitue un excellent outil d'aide à la décision pour identifier les clients les plus susceptibles de souscrire.

```
> print(df_test_sample[, c("ID", "Score")])
```

|    | ID   | Score  |
|----|------|--------|
| 1  | 1020 | 67.83  |
| 2  | 1021 | 0.94   |
| 3  | 1022 | 25.47  |
| 4  | 1023 | 11.57  |
| 5  | 1024 | 25.36  |
| 6  | 1025 | 16.34  |
| 7  | 1026 | 6.59   |
| 8  | 1027 | 30.40  |
| 9  | 1028 | 39.69  |
| 10 | 1029 | 18.29  |
| 11 | 1030 | 22.54  |
| 12 | 1031 | 31.17  |
| 13 | 1032 | 36.40  |
| 14 | 1033 | 51.91  |
| 15 | 1034 | 29.07  |
| 16 | 1035 | 7.35   |
| 17 | 1036 | 3.36   |
| 18 | 1037 | 1.78   |
| 19 | 1038 | 24.78  |
| 20 | 1039 | 1.48   |
| 21 | 1040 | 0.45   |
| 22 | 1041 | 0.61   |
| 23 | 1042 | 1.46   |
| 24 | 1043 | 1.46   |
| 25 | 1044 | 0.67   |
| 26 | 1045 | 14.45  |
| 27 | 1046 | 15.42  |
| 28 | 1047 | 32.29  |
| 29 | 1048 | 25.19  |
| 30 | 1049 | 35.84  |
| 31 | 1050 | 28.04  |
| 32 | 1051 | 2.60   |
| 33 | 1052 | 28.30  |
| 34 | 1053 | 38.41  |
| 35 | 1054 | 11.06  |
| 36 | 1055 | 100.00 |
| 37 | 1056 | 4.93   |
| 38 | 1057 | 100.00 |
| 39 | 1058 | 1.17   |
| 40 | 1059 | 4.10   |

|    |      |       |
|----|------|-------|
| 41 | 1060 | 3.09  |
| 42 | 1061 | 0.71  |
| 43 | 1062 | 2.75  |
| 44 | 1063 | 1.84  |
| 45 | 1064 | 3.51  |
| 46 | 1065 | 22.57 |
| 47 | 1066 | 4.92  |
| 48 | 1067 | 80.45 |
| 49 | 1068 | 2.08  |
| 50 | 1069 | 2.75  |

Le tableau de résultats de l'analyse fournit un score d'appétence pour la carte Mastercard Gold, exprimé en pourcentage, ce qui permet une lecture intuitive. Par exemple, l'individu identifié par l'ID 1067 présente un score de 80,45 ce qui signifie qu'il a environ 80,45 % de chances de souscrire à cette carte. À l'inverse, des clients comme celui avec l'ID 1059, affichant un score de seulement 4,10, sont très peu susceptibles de souscrire. Ces scores permettent ainsi de classer les individus selon leur probabilité de souscription, et d'identifier les profils les plus prometteurs pour des actions marketing ciblées.

## **Bibliographie**

### **Méthodologie et Analyses Statistiques**

Agresti, A. (2018). *An Introduction to Categorical Data Analysis*. Wiley.

James, G., Witten, D., Hastie, T., & Tibshirani, R. (2021). *An Introduction to Statistical Learning with Applications in R*. Springer.

Hosmer, D. W., Lemeshow, S., & Sturdivant, R. X. (2013). *Applied Logistic Regression*. Wiley.

### **Microéconométrie et Scoring Bancaire**

Greene, W. H. (2012). *Econometric Analysis*. Pearson Education.

Hand, D. J., & Henley, W. E. (1997). *Statistical Classification Methods in Consumer Credit Scoring: A Review*. Journal of the Royal Statistical Society, Series A (Statistics in Society), 160(3), 523-541.

### **Modélisation Économétrique et Régression Logistique**

Wooldridge, J. M. (2016). *Introductory Econometrics: A Modern Approach*. Cengage Learning.

Menard, S. (2002). *Applied Logistic Regression Analysis*. SAGE Publications.

Banque et Taux d'Endettement

Banque de France. (2024). *Taux d'endettement et réglementation bancaire en France*.

Consulté le 10 mars 2025, à l'adresse : <https://www.banque-france.fr>